



$\otimes$ : Element-wise multiplication     $\odot$ : Dot production     $\mathcal{S}_{rl}$ : Relation score  
 $\tilde{I}$ : Warped future frame     $\mathcal{E}$ : Encoder     $\mathcal{M}$ : Region mask set  
 $\hat{I}$ : Predicted future frame     $\mathcal{D}$ : Decoder     $E_s$ : Scene Embedding  
 $I$ : Ground-truth frame     $w$ : Conv filter     $\psi_r$ : Relation score map  
 $\mathcal{RL}$ : Relation Learning module     $e_o$ : Object consensus embedding